

$$\alpha(\mathbf{x}_0, \mathbf{x}_0) \mathbf{v}_0$$

$$\alpha(\mathbf{x}_0, \mathbf{x}_4) \mathbf{v}_0 + \alpha(\mathbf{x}_1, \mathbf{x}_4) \mathbf{v}_1 + \dots + \alpha(\mathbf{x}_4, \mathbf{x}_4) \mathbf{v}_4$$

Masked Attention Head

$\mathbf{K}, \mathbf{Q}, \mathbf{V}$

$\mathbf{x}_0$

$\mathbf{x}_1$

$\mathbf{x}_2$

$\mathbf{x}_3$

$\mathbf{x}_4$

$$\text{Softmax} \left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{D_q}} \right)$$

0.6	0.1	0.1	0.1	0.1
0.2	0.4	0.1	0.1	0.2
0.2	0.1	0.5	0.1	0.1
0.3	0.2	0.1	0.3	0.1
0.1	0.1	0.2	0.2	0.4